

Πανεπιστήμιο Θεσσαλίας  
Τμήμα Πληροφορικής και Τηλεπικοινωνιών

---

# Ανάλυση Δεδομένων NYC Yellow Taxi με Apache Spark

---

Εξαμηνιαία Εργασία  
Συστήματα Διαχείρισης Μεγάλου Όγκου Δεδομένων  
6ο Εξάμηνο – Ακαδημαϊκό Έτος 2025–2026

Αριθμός Μητρώου: 2121261

Username: ipelekanos

Repository: <https://github.com/GiannisPel/project2026-bigdata>

HDFS Namespace: ipelekanos-priv

*Η εργασία εκτελέστηκε σε Apache Spark 3.5.8 / Kubernetes / HDFS.*

*Repository: <https://github.com/GiannisPel/project2026-bigdata>*

## Contents

---

|                                                  |           |
|--------------------------------------------------|-----------|
| <b>1 Περιγραφή Δεδομένων</b>                     | <b>5</b>  |
| <b>2 Περιβάλλον</b>                              | <b>5</b>  |
| 2.1 Τεχνικό Περιβάλλον . . . . .                 | 5         |
| 2.2 Προαπαιτούμενα Εκτέλεσης . . . . .           | 6         |
| 2.3 Spark UI – Port Forwarding . . . . .         | 6         |
| 2.4 Σύνδεση με τους Οδηγούς . . . . .            | 6         |
| <b>3 Εξατομίκευση Εργασίας</b>                   | <b>6</b>  |
| 3.1 Υπολογισμός Παραμέτρων . . . . .             | 6         |
| 3.2 Ερμηνεία στον Πραγματικό Κόσμο . . . . .     | 7         |
| 3.3 Εφαρμογή Εξατομίκευσης ανά Ερώτημα . . . . . | 7         |
| <b>4 Προετοιμασία Δεδομένων και Parquet</b>      | <b>8</b>  |
| 4.1 Script και Εκτέλεση . . . . .                | 8         |
| 4.2 Τεχνικές Απαιτήσεις . . . . .                | 8         |
| 4.3 Metrics Προετοιμασίας . . . . .              | 8         |
| 4.4 Partitioning . . . . .                       | 10        |
| 4.5 CSV vs Parquet Size . . . . .                | 10        |
| 4.6 HDFS Outputs . . . . .                       | 10        |
| <b>5 Διερευνητική Ανάλυση Δεδομένων (EDA)</b>    | <b>10</b> |
| 5.1 Script και Εκτέλεση . . . . .                | 10        |
| 5.2 Πλήθη Εγγραφών . . . . .                     | 11        |
| 5.3 Τεκμήρια EDA . . . . .                       | 11        |
| 5.4 Ανάλυση Nulls (2024) . . . . .               | 11        |
| 5.5 Κατανομή Pickup Hour . . . . .               | 12        |
| 5.6 Κατανομή Pickup Day (2024) . . . . .         | 12        |
| 5.7 Top Pickup Zones (2024) . . . . .            | 12        |
| 5.8 Κατανομές Log-Scale . . . . .                | 13        |
| 5.9 Δείγμα Ανωμαλιών . . . . .                   | 13        |
| <b>6 Ημερολόγιο Υποθέσεων (Hypothesis Log)</b>   | <b>13</b> |
| 6.1 Q1 – Χρονικό Προφίλ Ζήτησης . . . . .        | 13        |
| 6.2 Q2 – Ταχύτητα/Συμφόρηση 2015 . . . . .       | 13        |
| 6.3 Q3 – Έσοδα και Αποδοτικότητα . . . . .       | 14        |
| 6.4 Q4 – Πληρωμές και Φιλοδωρήματα . . . . .     | 14        |

|           |                                                                           |           |
|-----------|---------------------------------------------------------------------------|-----------|
| 6.5       | Q5 – Αεροδρόμια και Borough Flows . . . . .                               | 14        |
| 6.6       | Q6 – Ανισορροπία Ζωνών . . . . .                                          | 14        |
| <b>7</b>  | <b>Executive Summary</b>                                                  | <b>15</b> |
| <b>8</b>  | <b>Q1: Χρονικό Προφίλ Ζήτησης Ταξί</b>                                    | <b>15</b> |
| 8.1       | Τι Ζητάει η Εκφώνηση . . . . .                                            | 15        |
| 8.2       | Υποερωτήματα / Ζητούμενα Εκφώνησης . . . . .                              | 15        |
| 8.3       | Απαιτήσεις Εμπλοκής . . . . .                                             | 16        |
| 8.4       | Προσωπικό Φίλτρο . . . . .                                                | 16        |
| 8.5       | Inputs και Data Quality Filters . . . . .                                 | 16        |
| 8.6       | Υλοποιήσεις / APIs . . . . .                                              | 17        |
| 8.7       | Βασικά Αποτελέσματα . . . . .                                             | 17        |
| 8.8       | Physical/Logical Plan . . . . .                                           | 18        |
| 8.9       | Caveats . . . . .                                                         | 18        |
| <b>9</b>  | <b>Q2: Διάρκεια, Ταχύτητα και Ενδείξεις Συμφοράς</b>                      | <b>18</b> |
| 9.1       | Τι Ζητάει η Εκφώνηση . . . . .                                            | 18        |
| 9.2       | Υποερωτήματα / Ζητούμενα Εκφώνησης . . . . .                              | 18        |
| 9.3       | Απαιτήσεις Εμπλοκής . . . . .                                             | 19        |
| 9.4       | Προσωπικό Φίλτρο . . . . .                                                | 19        |
| 9.5       | Inputs και Data Quality Filters . . . . .                                 | 20        |
| 9.6       | Υλοποιήσεις / APIs . . . . .                                              | 20        |
| 9.7       | Βασικά Αποτελέσματα . . . . .                                             | 20        |
| 9.8       | Physical/Logical Plan Discussion . . . . .                                | 21        |
| <b>10</b> | <b>Q3: Έσοδα, Απόδοση Διαδρομών και Ζώνες Υψηλής Οικονομικής Σημασίας</b> | <b>21</b> |
| 10.1      | Τι Ζητάει η Εκφώνηση . . . . .                                            | 21        |
| 10.2      | Απαιτήσεις Εμπλοκής . . . . .                                             | 21        |
| 10.3      | Inputs και Φίλτρα . . . . .                                               | 22        |
| 10.4      | Υλοποιήσεις / APIs . . . . .                                              | 22        |
| 10.5      | Βασικά Αποτελέσματα . . . . .                                             | 23        |
| <b>11</b> | <b>Q4: Τρόπος Πληρωμής και Συμπεριφορά Φιλοδωρήματος</b>                  | <b>23</b> |
| 11.1      | Τι Ζητάει η Εκφώνηση . . . . .                                            | 23        |
| 11.2      | Απαιτήσεις Εμπλοκής . . . . .                                             | 23        |
| 11.3      | Βασικά Αποτελέσματα . . . . .                                             | 24        |
| 11.4      | Υλοποιήσεις / APIs . . . . .                                              | 24        |
| <b>12</b> | <b>Q5: Αεροδρόμια και Ροές Μεταξύ Δήμων</b>                               | <b>24</b> |

|                                                                |           |
|----------------------------------------------------------------|-----------|
| 12.1 Τι Ζητάει η Εκφώνηση . . . . .                            | 24        |
| 12.2 Απαιτήσεις Εμπλοκής . . . . .                             | 25        |
| 12.3 Βασικά Αποτελέσματα . . . . .                             | 25        |
| 12.4 Υλοποιήσεις / APIs . . . . .                              | 26        |
| <b>13 Q6: Ανισορροπία Επιβιβάσεων και Αποβιβάσεων ανά Ζώνη</b> | <b>26</b> |
| 13.1 Τι Ζητάει η Εκφώνηση . . . . .                            | 26        |
| 13.2 Απαιτήσεις Εμπλοκής . . . . .                             | 26        |
| 13.3 Βασικά Αποτελέσματα . . . . .                             | 27        |
| 13.4 Υλοποιήσεις / APIs . . . . .                              | 28        |
| <b>14 Q6 OD-Halves: Πείραμα Κλιμάκωσης Εκτελεστών</b>          | <b>28</b> |
| 14.1 Στόχος και Σχεδιασμός . . . . .                           | 28        |
| 14.2 Executor Configurations . . . . .                         | 29        |
| 14.3 Runtimes (Cold / Warm) . . . . .                          | 29        |
| 14.4 Ερμηνεία Scaling και Caching . . . . .                    | 29        |
| 14.5 Βασικά OD Αποτελέσματα . . . . .                          | 30        |
| <b>15 Μελέτη Catalyst και Φυσικών Σχεδίων Εκτέλεσης</b>        | <b>30</b> |
| 15.1 Q1 – CSV vs Parquet Scan . . . . .                        | 30        |
| 15.2 Q2 – Built-in vs Python UDF . . . . .                     | 30        |
| 15.3 Q3 – Partition Pruning . . . . .                          | 31        |
| 15.4 Q4 – Conditional Aggregation . . . . .                    | 31        |
| 15.5 Q5 – Double Lookup Join και Broadcast . . . . .           | 31        |
| 15.6 Q6 – Full Outer Join και OD-Halves . . . . .              | 31        |
| <b>16 Performance και Scaling Discussion</b>                   | <b>32</b> |
| 16.1 RDD vs DataFrame vs SQL (Q1) . . . . .                    | 32        |
| 16.2 CSV vs Parquet . . . . .                                  | 32        |
| 16.3 UDF vs Built-in (Q2) . . . . .                            | 33        |
| 16.4 Broadcast vs No-broadcast (Q5) . . . . .                  | 33        |
| 16.5 OD-Halves Scaling . . . . .                               | 33        |
| <b>17 Reproducibility / RUNBOOK Summary</b>                    | <b>33</b> |
| <b>18 Limitations και Data Quality Caveats</b>                 | <b>34</b> |
| <b>Παράρτημα</b>                                               | <b>35</b> |
| <b>A Λίστα Scripts</b>                                         | <b>35</b> |
| <b>B Spark Application IDs</b>                                 | <b>35</b> |

|   |                              |    |
|---|------------------------------|----|
| C | Λίστα Plan Files (27 αρχεία) | 37 |
| D | HDFS Paths                   | 38 |
| E | Λίστα Plots (21 αρχεία)      | 39 |
| F | Πίνακας Κάλυψης              | 39 |

# 1. Περιγραφή Δεδομένων

Τα δεδομένα αφορούν πραγματικές διαδρομές κίτρινων ταξί στη Νέα Υόρκη, διαθέσιμα από την NYC Taxi and Limousine Commission. Τα αρχεία βρίσκονται στο HDFS του εργαστηρίου.

| Σύνολο<br>Δεδομένων      | Περιγραφή                                    | HDFS URI                 |
|--------------------------|----------------------------------------------|--------------------------|
| tripdata_2015.csv        | Διαδρομές 2015 με GPS<br>συντεταγμένες       | yellow_tripdata_2015.csv |
| yellow_tripdata_2024.csv | Διαδρομές 2024 με TLC<br>LocationID κωδικούς | tripdata_2024.csv        |
| taxi_zone_lookup.csv     | Αναστοίχιση LocationID →<br>Borough/Zone     | taxi_zone_lookup.csv     |

Table 1: Σύνολα δεδομένων

**Διαφορές σχήματος:** Το 2015 dataset περιέχει GPS συντεταγμένες (pickup\_longitude/latitude, dropoff\_longitude/latitude), που επιτρέπουν υπολογισμό Haversine απόστασης. Το 2024 dataset χρησιμοποιεί PULocationID/DOLocationID κωδικούς και απαιτεί join με taxi\_zone\_lookup για γεωγραφική πληροφορία.

**Ποιότητα δεδομένων:** Τα ακατέργαστα δεδομένα δεν είναι καθαρά. Ενδέχεται να υπάρχουν nulls σε timestamps, μηδενικές ή αρνητικές αποστάσεις/ποσά, λανθασμένο έτος, ή συντεταγμένες εκτός Νέας Υόρκης. Η προετοιμασία εφαρμόζει ρητές μετατροπές και καταγράφει metrics ποιότητας.

# 2. Περιβάλλον

## 2.1 Τεχνικό Περιβάλλον

| Στοιχείο               | Τιμή            |
|------------------------|-----------------|
| Λειτουργικό σύστημα    | WSL2 Ubuntu     |
| Apache Spark (client)  | 3.5.8           |
| Apache Hadoop (client) | 3.4.1           |
| Kubernetes namespace   | ipelekanos-priv |

Table 2: Τεχνικό περιβάλλον εκτέλεσης

## 2.2 Προαπαιτούμενα Εκτέλεσης

```
source ~/bigdata-env.sh
command -v spark-submit && command -v hdfs
kubectl config current-context
getent hosts hdfs-namenode.default.svc.cluster.local
hdfs dfs -ls /data
```

## 2.3 Spark UI – Port Forwarding

```
kubectl -n "ipelekanos-priv" port-forward pod/<driver-pod-name>
4040:4040
# Anoigma: http://localhost:4040
# Tabs: Jobs, Stages, SQL/DataFrame (plans), Executors
```

**Snapshots:** όλα τα snapshots που ζητήθηκαν είναι στο /screenshots directory

## 2.4 Σύνδεση με τους Οδηγούς

Η εργασία ακολουθεί τη ροή των οδηγών:

- docs/04\_remote-spark-kubernetes: ρύθμιση WSL, VPN, Hadoop/Spark client, spark-defaults.conf, HDFS paths, Kubernetes namespace.
- docs/05\_cluster-queries-rdd-df-sql: spark-submit pattern, RDD/DataFrame/SQL implementations, HDFS I/O, plan inspection.

## 3. Εξατομίκευση Εργασίας

### 3.1 Υπολογισμός Παραμέτρων

Αριθμός Μητρώου:  $A = 2121261$

| Παράμετρος | Τύπος              | Τιμή      |
|------------|--------------------|-----------|
| h          | Ώρα έναρξης        | <b>21</b> |
| L          | Μήκος παραθύρου    | <b>4</b>  |
| d          | Ημέρα έναρξης      | <b>26</b> |
| K          | Top-K αποτελέσματα | <b>20</b> |

**Table 3:** Υπολογισμός εξατομικευμένων παραμέτρων από AM

Εξατομικευμένες τιμές:

```

hours_window = [21, 22, 23, 0] # kukliko [h, h+4) = [21, 25)
               mod 24
days_2024    = [26, 27, 28]    # d, d+1, d+2
top_k         = 20

```

**Κυκλικότητα:**  $h + L = 21 + 4 = 25 \geq 24$ , άρα  $[21, 24) \cup [0, 1) =$  ώρες 21, 22, 23, 0.

### 3.2 Ερμηνεία στον Πραγματικό Κόσμο

Οι ώρες [21, 22, 23, 0] καλύπτουν το βραδινό και μεταμεσονύκτιο παράθυρο:

- **21:00–21:59 (Evening):** Αρχή έντονης βραδινής δραστηριότητας, έξοδοι από εστιατόρια, θέατρα, πρώτες μετακινήσεις διασκέδασης.
- **22:00–22:59 (Late):** Αυξημένη κίνηση διασκέδασης και επιστροφών.
- **23:00–23:59 (Late):** Late evening, μετακινήσεις από nightlife, αυξανόμενα airport movements.
- **00:00–00:59 (Late):** Μεταμεσονύκτιο, επιστροφές, airport movements, nightlife returns.

Αυτό το παράθυρο αντιστοιχεί σε μετάβαση από evening activity (post-dinner, entertainment) σε late-night (nightlife returns, international flight departures). Αναμένω υψηλή ζήτηση από αεροδρόμια και κεντρικές περιοχές του Manhattan.

### 3.3 Εφαρμογή Εξατομίκευσης ανά Ερώτημα

| Ερώτημα      | Dataset | Φίλτρο                                         |
|--------------|---------|------------------------------------------------|
| Q1           | 2024    | days [26, 27, 28] AND hours [21, 22, 23, 0]    |
| Q2           | 2015    | hours [21, 22, 23, 0]                          |
| Q3           | 2024    | days [26, 27, 28] AND hours [21, 22, 23, 0]    |
| Q4           | 2024    | days [26, 27, 28] AND hours [21, 22, 23, 0]    |
| Q5           | 2024    | days [26, 27, 28] AND hours [21, 22, 23, 0]    |
| Q6 imbalance | 2024    | days [26, 27, 28] AND hours [21, 22, 23, 0]    |
| Q6 OD-Halves | 2024    | Δεν χρησιμοποιεί personalization – πλήρες 2024 |

**Table 4:** Εφαρμογή εξατομίκευσης ανά ερώτημα

Η εξατομίκευση γίνεται στο `common.py` και περνιέται με CLI argument `-student-id 2121261`.

## 4. Προετοιμασία Δεδομένων και Parquet

### 4.1 Script και Εκτέλεση

- **Script:** `project2026/jobs/prepare_parquet.py`
- **Βοηθητικό:** `project2026/jobs/common.py`
- **Spark App ID:** `spark-614263c24d01428d9e27686116391b3b`
- **Metrics:** `prepare_parquet_metrics.json`

```
run_started_at   = 2026-05-02T07:29:26.698933+00:00
run_finished_at  = 2026-05-02T08:24:57.764875+00:00
```

### 4.2 Τεχνικές Απαιτήσεις

Η προετοιμασία υλοποιεί:

- **Timestamp parsing:** 2015: `yyyy-MM-dd HH:mm:ss`, 2024: `yyyy-MM-dd' T' HH:mm:ss.S`
- **Κανονικοποίηση στηλών:** `vendor_id`, `pickup_ts`, `dropoff_ts`, `pu_location_id`, `do_location_id`.
- **Βοηθητικές στήλες** (βλ. Πίνακα 5).
- **Απόρριψη wrong-year rows:** Κρατούνται μόνο εγγραφές με `year (pickup_ts)` = 2015/2024.

| Στήλη                         | Τύπος     | Περιγραφή                        |
|-------------------------------|-----------|----------------------------------|
| <code>pickup_ts</code>        | timestamp | Timestamp επιβίβασης             |
| <code>dropoff_ts</code>       | timestamp | Timestamp αποβίβασης             |
| <code>pickup_date</code>      | date      | Ημερομηνία επιβίβασης            |
| <code>pickup_day</code>       | int       | Ημέρα μήνα (1–31)                |
| <code>pickup_hour</code>      | int       | Ώρα (0–23)                       |
| <code>duration_minutes</code> | double    | Διάρκεια σε λεπτά                |
| <code>trip_distance_km</code> | double    | Απόσταση σε km (miles * 1.60934) |

**Table 5:** Βοηθητικές στήλες που προστίθενται κατά την προετοιμασία

### 4.3 Metrics Προετοιμασίας

`yellow_tripdata_2015:`

| Μετρική                   | Τιμή                            |
|---------------------------|---------------------------------|
| raw_row_count             | 12.748.986                      |
| prepared_row_count        | 12.748.986                      |
| bad_or_null_pickup_ts     | 0                               |
| wrong_year_rejected_count | 0                               |
| partition_columns         | [pickup_hour]                   |
| conversion_time_seconds   | 999,274                         |
| parquet_output_size_bytes | 454.657.612 ( $\approx$ 433 MB) |
| parquet_file_count        | 360                             |
| min_pickup_ts             | 2015-01-01 00:00:00             |
| max_pickup_ts             | 2015-01-31 23:59:59             |

**Table 6:** Metrics προετοιμασίας 2015**yellow\_tripdata\_2024:**

| Μετρική                   | Τιμή                              |
|---------------------------|-----------------------------------|
| raw_row_count             | 41.169.720                        |
| prepared_row_count        | <b>41.169.664</b>                 |
| bad_or_null_pickup_ts     | 0                                 |
| wrong_year_rejected_count | <b>56</b>                         |
| partition_columns         | [pickup_day]                      |
| conversion_time_seconds   | 2.330,169                         |
| parquet_output_size_bytes | 1.038.062.261 ( $\approx$ 990 MB) |
| parquet_file_count        | 669                               |
| min_pickup_ts             | 2002-12-31 16:46:07               |
| max_pickup_ts             | 2026-06-26 23:53:12               |

**Table 7:** Metrics προετοιμασίας 2024

**Data Quality Finding – 56 Wrong-Year Rows:** Το raw 2024 dataset περιείχε 56 εγγραφές με year(pickup\_ts) όχι 2024 (timestamps από 2002 έως 2026). Αυτές απορρίφθηκαν.

**Data Quality Note – Extreme Timestamps:** Τα min/max timestamps (2002-12-31, 2026-06-26) επιβεβαιώνουν ότι τα wrong-year records ήταν εσφαλμένα. year filter τα αφαιρεί αποτελεσματικά.

**taxi\_zone\_lookup:** 265 εγγραφές, 265 prepared, χρόνος 0,698s, μέγεθος Parquet  $\approx$  6 KB, 1 αρχείο.

#### 4.4 Partitioning

| Dataset          | Partition Column | Παιδαγωγικός Στόχος                                  |
|------------------|------------------|------------------------------------------------------|
| 2015             | pickup_hour      | Partition pruning στο ωριαίο φίλτρο Q2               |
| 2024             | pickup_day       | Partition pruning στο τριήμερο φίλτρο Q1/Q3/Q4/Q5/Q6 |
| taxi_zone_lookup | -                | Δεν χρειάστηκε γιατί είναι μικρός πίνακας            |

**Table 8:** Επιλογές partitioning

#### 4.5 CSV vs Parquet Size

Τα μεγέθη μετρήθηκαν με `hdfs dfs -du -h` και αφορούν το πραγματικό μέγεθος των αρχείων (πρώτη στήλη, χωρίς replication factor).

| Dataset | CSV Size | Parquet Size | Parquet / CSV | Σχόλιο          |
|---------|----------|--------------|---------------|-----------------|
| 2015    | 1,8 GiB  | ≈434 MB      | ≈24%          | ≈4,2× μικρότερο |
| 2024    | 4,2 GiB  | ≈990 MB      | ≈23%          | ≈4,3× μικρότερο |

**Table 9:** Σύγκριση μεγέθους CSV vs Parquet (από `hdfs dfs -du -h`)

Το Parquet καταλαμβάνει περίπου το ένα τέταρτο του CSV μεγέθους, επειδή είναι columnar και συμπιεσμένο. Αυτό βοηθά ιδιαίτερα σε queries που διαβάζουν υποσύνολο στηλών και εφαρμόζουν partition pruning.

#### 4.6 HDFS Outputs

```
/user/ipelekanos/project2026/data/parquet/yellow_tripdata_2015/ (
  pickup_hour)
/user/ipelekanos/project2026/data/parquet/yellow_tripdata_2024/ (
  pickup_day)
/user/ipelekanos/project2026/data/parquet/taxi_zone_lookup/
```

## 5. Διερευνητική Ανάλυση Δεδομένων (EDA)

### 5.1 Script και Εκτέλεση

- **Script:** `project2026/jobs/eda.py`

- **Spark App ID:** spark-7055d17eb1074174a68bf1a8e581be7a
- **Elapsed:** Περίπου 67 λεπτά
- **Metrics:** eda\_metrics.json

Η EDA εκτελείται πάνω στα **prepared Parquet** datasets, με year filter μόνο και **χωρίς** εξατομικευμένα φίλτρα. Στόχος: παρατήρηση πλήρους κατανομής πριν τον περιορισμό.

## 5.2 Πλήθη Εγγραφών

| Dataset              | Εγγραφές          |
|----------------------|-------------------|
| yellow_tripdata_2015 | <b>12.748.986</b> |
| yellow_tripdata_2024 | <b>41.169.664</b> |
| taxi_zone_lookup     | <b>265</b>        |

**Table 10:** Πλήθη εγγραφών μετά preparation

## 5.3 Τεκμήρια EDA

| Τεκμήριο                 | Artifact / Κατάσταση                          |
|--------------------------|-----------------------------------------------|
| Schema dump              | eda_metrics.json                              |
| Describe/basic stats     | eda_metrics.json                              |
| Null percentages         | null_percentages table + null_percentages.png |
| Pickup hour distribution | pickup_hour_distribution.png                  |
| Pickup day distribution  | pickup_day_distribution_2024.png              |
| Trip distance histogram  | trip_distance_log_histogram.png               |
| Total amount histogram   | total_amount_log_histogram.png                |
| Joinability check        | Verify in eda_metrics.json                    |
| Top-10 pickup zones      | top_10_pickup_zones_2024.png                  |
| Anomaly samples          | Partial (από Q2 fastest/slowest)              |

**Table 11:** Τεκμήρια EDA και κατάσταση

## 5.4 Ανάλυση Nulls (2024)

Null rows se epilegmena pedia: 4.091.232 = 9.937492%

Affected fields:

```
airport_fee
congestion_surcharge
passenger_count
rate_code_id
```

```
store_and_fwd_flag
```

Τα υπόλοιπα πεδία (fare\_amount, tip\_amount, total\_amount, pickup\_ts, dropoff\_ts, pu\_location\_id, do\_location\_id) έχουν ελάχιστα ή μηδενικά nulls.

### 5.5 Κατανομή Pickup Hour

| Ώρα                       | 2015 Trips     | 2024 Trips       |
|---------------------------|----------------|------------------|
| <b>Peak 2015 (ώρα 19)</b> | <b>805.230</b> | –                |
| <b>Peak 2024 (ώρα 18)</b> | –              | <b>2.955.735</b> |
| Personalized ώρα 21       | –              | 2.405.757        |
| Personalized ώρα 22       | –              | 2.228.352        |
| Personalized ώρα 23       | –              | 1.731.941        |
| Personalized ώρα 0        | –              | 1.192.044        |

**Table 12:** Κατανομή pickup hour (επιλεγμένες ώρες)

Και τα δύο έτη έχουν peak κατά την απογευματινή αιχμή. Το 2024 peak είναι μία ώρα νωρίτερα (18:00 vs 19:00). Οι personalized ώρες 21–0 είναι post-peak αλλά active.

### 5.6 Κατανομή Pickup Day (2024)

| Ημέρα                  | Trips            |
|------------------------|------------------|
| Max (ημέρα 14)         | 1.451.759        |
| Min (ημέρα 31)         | 735.449          |
| <b>Personalized 26</b> | <b>1.291.825</b> |
| <b>Personalized 27</b> | <b>1.296.339</b> |
| <b>Personalized 28</b> | <b>1.265.784</b> |

**Table 13:** Κατανομή pickup day (επιλεγμένες ημέρες)

Οι personalized ημέρες 26–28 έχουν παρόμοιο αριθμό trips (1,26–1,30M), κοντά στον μέσο όρο.

### 5.7 Top Pickup Zones (2024)

JFK Airport (Queens): **1.989.986** trips – πρώτη θέση με σαφή απόσταση. Αυτό είναι κρίσιμο για Q3/Q5/Q6.

## 5.8 Κατανομές Log-Scale

**Total amount log histogram:** Αποκαλύπτει σαφή skew. Αρνητικές τιμές εξαιρούνται από τα log buckets που σημαίνει data quality issue.

**Trip distance log histogram:** Οι περισσότερες διαδρομές είναι σύντομες. Ακραία outliers (π.χ. trip\_distance = εκατομμύρια miles) δεν αφαιρούνται από τα basic validity filters.

## 5.9 Δείγμα Ανωμαλιών

- **Fastest anomaly:** trip\_distance κάπου στα 18.990.260 km σε 8,43 λεπτά περίπου, Haversine περίπου 4,20 km. Εσφαλμένη εγγραφή trip\_distance, αδύνατο φυσικά.
- **Slowest anomaly:** Διάρκεια περίπου 25.367 λεπτά για 1,609 km.

## 6. Ημερολόγιο Υποθέσεων (Hypothesis Log)

---

Πριν από οποιαδήποτε εκτέλεση ερωτήματος, κατέγραψα τις παρακάτω υποθέσεις.

### 6.1 Q1 – Χρονικό Προφίλ Ζήτησης

**Υπόθεση:** Στις ώρες 21–0 αναμένω αυξημένη ζήτηση στις πρώτες ώρες (21:00–22:00) λόγω βραδινής εξόδου. Το JFK Airport και οι κεντρικές ζώνες Manhattan αναμένεται να συνεισφέρουν σημαντικά. Η αιχμή αναμένεται στις 21:00 ή 22:00 της ημέρας που εμπίπτει σε καθημερινή (Πέμπτη ή Παρασκευή).

**Αποτέλεσμα:** Peak: 2024-03-28 ώρα 21, 9.431 trips (Πέμπτη). Late band 68,586% (ώρες 22, 23, 0 μαζί).

**Επαλήθευση:** Μερική – η ώρα 21 είναι peak, αλλά το Late band κυριαρχεί λόγω τριών ωρών.

### 6.2 Q2 – Ταχύτητα/Συμφόρηση 2015

**Υπόθεση:** Η ώρα 00:00 αναμένω χαμηλότερη κυκλοφορία, άρα υψηλότερη avg\_speed. Η ώρα 21 αναμένω πιο συμφορημένη λόγω βραδινής εξόδου.

**Αποτέλεσμα:** Ώρα 21: τα περισσότερα trips AND υψηλότερο congestion\_candidate\_share (0,160).

**Επαλήθευση:** Μερική – congestion hypothesis επιβεβαιώθηκε για ώρα 21.

### 6.3 Q3 – Έσοδα και Αποδοτικότητα

**Υπόθεση:** Total revenue θα κυριαρχείται από airport zones. Τα rankings total\_revenue και revenue\_per\_mile αναμένω να διαφέρουν. Το JFK αναμένεται πρώτο σε total revenue.

**Αποτέλεσμα:** JFK Airport/long #1 total\_revenue (\$3,27M). JFK Airport/very\_short #1 revenue\_per\_mile (134,87) και revenue\_per\_minute (19,90).

**Επαλήθευση:** Επιβεβαιώθηκε πλήρως.

### 6.4 Q4 – Πληρωμές και Φιλοδωρήματα

**Υπόθεση:** Card payments αναμένεται να κυριαρχούν ( $\approx 85\%+$ ). Η recorded tip rate για card θα είναι υψηλότερη λόγω recording bias. Δεν αναμένεται αιτιακή σχέση – descriptive finding μόνο.

**Αποτέλεσμα:** Card share 86,8%–87,7%. Avg card tip rate  $\approx 24,2\%$ – $25,2\%$ . Όρα 0: highest card share (0,877259).

**Επαλήθευση:** Επιβεβαιώθηκε – με ρητή δήλωση ότι είναι descriptive.

### 6.5 Q5 – Αεροδρόμια και Borough Flows

**Υπόθεση:** Manhattan→Manhattan θα είναι μακράν η μεγαλύτερη ροή. Airport routes: υψηλότερο avg\_total\_amount και avg\_trip\_distance. Queens→Manhattan: μεγάλο airport\_trip\_share λόγω JFK.

**Αποτέλεσμα:** Manhattan→Manhattan: 554.348 trips, share 0,809043. Queens→Manhattan: airport\_trip\_share  $\approx 0,940257$ . JFK→Outside of NYC avg\_total\_amount \$126,50.

**Επαλήθευση:** Επιβεβαιώθηκε πλήρως.

### 6.6 Q6 – Ανισορροπία Ζωνών

**Υπόθεση:** Αεροδρόμια (JFK, LaGuardia) αναμένεται positive net\_pickups γιατί οι ταξιδιώτες φεύγουν από τη ΝΥ. Residential Manhattan zones αναμένεται negative net\_pickups καθώς ο κόσμος επιστρέφει βράδυ.

**Αποτέλεσμα:** JFK Airport ώρα 22: net\_pickups=11.834, ratio=0,904. LaGuardia ώρα 21: ratio=0,963 (highest abs ratio). Upper East Side North ώρα 22: net\_pickups=-3.448.

**Επαλήθευση:** Επιβεβαιώθηκε πλήρως.

## 7. Executive Summary

---

Η εργασία αναλύει NYC Yellow Taxi δεδομένα (2015: 12.748.986 εγγραφές, 2024: 41.169.664 εγγραφές) χρησιμοποιώντας Apache Spark 3.5.8 σε Kubernetes, με HDFS αποθήκευση.

**Εξατομίκευση (AM 2121261):** Ώρες [21, 22, 23, 0], ημέρες 2024 [26, 27, 28], top\_k=20 – βραδινό/μεταμεσονύχτιο παράθυρο.

**Βασικά ευρήματα:**

- **Ζήτηση (Q1):** Peak στις 21:00 της 28/3/2024 (Πέμπτη) με 9.431 trips.
- **Συμφόρηση (Q2):** Ώρα 21 έχει υψηλότερο congestion\_candidate\_share (0,160).
- **Έσοδα (Q3):** JFK Airport κυριαρχεί σε total revenue (\$3,27M) και efficiency metrics.
- **Πληρωμές (Q4):** Card share  $\approx 87\%$ . Avg card tip rate  $\approx 24\%$ . Descriptive – όχι causal.
- **Ροές (Q5):** Manhattan→Manhattan κυριαρχεί (80,9%). Airport routes: avg amount \$80–\$126.

## 8. Q1: Χρονικό Προφίλ Ζήτησης Ταξί

---

### 8.1 Τι Ζητάει η Εκφώνηση

Απάντηση στο: *πότε εμφανίζεται η μεγαλύτερη ζήτηση ταξί στο προσωπικό χρονικό παράθυρο;* Η ζήτηση μετρείται με trips count συν βοηθητικές μετρικές (απόσταση, διάρκεια, revenue). Παράγεται ranking (pickup\_date, pickup\_hour) και time\_band summary.

### 8.2 Υποερωτήματα / Ζητούμενα Εκφώνησης

Για κάθε (pickup\_date, pickup\_hour) υπολογίζω:

- trips, unique\_pickup\_zones, avg\_passenger\_count, avg\_duration\_minutes
- avg\_trip\_distance, avg\_total\_amount, total\_revenue, trip\_share\_in\_person

Επιστροφή: top-K ώρες-ημέρες (κατά trips  $\rightarrow$  total\_revenue  $\rightarrow$  pickup\_date  $\rightarrow$  pickup\_hour) + time\_band summary.

### 8.3 Απαιτήσεις Εμπλοκής

(α) **Υπόθεση πριν τη μέτρηση.** Βλ. §6.1 – αναμένω peak στις 21:00 καθημερινής λόγω βραδινής εξόδου. Η ώρα 21 καλύπτει το τέλος δείπνων, θεάτρων, πρώτες εξόδους – τυπικά η πιο απαιτητική ώρα στο NYC βράδυ. Η αιχμή αναμένεται σε Παρασκευή ή Πέμπτη.

(β) **Σύγκριση με γενικό προφίλ.** Από την EDA: peak 2024 στις 18:00 με 2.955.735 trips. Ώρα 21 έχει 2.405.757 trips (81,4% της peak). Το προσωπικό παράθυρο [21–0] αντιστοιχεί σε 81%–40% της peak ώρας – post-peak αλλά σημαντικά active. Σε σχέση με το ετήσιο προφίλ, οι ώρες 21–0 είναι above-average (μέσος όρος  $\approx 1.714.000$  trips/ώρα).

(γ) **Σύγκριση διεπαφών.** Βλ. §16. SQL Parquet είναι  $\approx 11,5\times$  ταχύτερο από RDD CSV. Το RDD API δεν αξιοποιεί Catalyst – χειροκίνητη parsing, reduceByKey, χωρίς columnar I/O.

(δ) **Σύντομη ερμηνεία.** Στο παράθυρο [21–0], η μεγαλύτερη ζήτηση είναι στις 21:00 της Πέμπτης 28 Μαρτίου 2024 (9.431 trips). Το πιο αξιοσημείωτο είναι ότι το Late band (22, 23, 0) κυριαρχεί στο 68,6% του συνόλου λόγω τριών ωρών. Ωστόσο η ανά-ώρα ζήτηση είναι υψηλότερη στις 21:00.

### 8.4 Προσωπικό Φίλτρο

```
pickup_day IN (26, 27, 28) AND pickup_hour IN (21, 22, 23, 0)
```

### 8.5 Inputs και Data Quality Filters

- **Dataset:** yellow\_tripdata\_2024 (CSV και Parquet)
- **Filters:** valid pickup\_ts/dropoff\_ts, duration\_minutes > 0, trip\_distance > 0, total\_amount > 0
- **Personalized filtered rows:** CSV/RDD = **685.192** | Parquet/SQL = **685.190** (διαφορά 2 rows, αμελητέα)

**Time-band definition:**

| Band      | Ώρες        |
|-----------|-------------|
| Night     | 00:00–05:59 |
| Morning   | 06:00–11:59 |
| Afternoon | 12:00–16:59 |
| Evening   | 17:00–21:59 |
| Late      | 22:00–23:59 |

**Table 14:** Ορισμός time bands

*Σημείωση:* Στα αποτελέσματα η ώρα 0 ομαδοποιείται στο Late band (επιλογή υλοποίησης). Επέλεξα Late  $\equiv \{22, 23, 0\}$  επειδή χαρακτηρίζουν όλες τη νυχτερινή μετακίνηση της ίδιας «βραδινής εξόδου».

## 8.6 Υλοποιήσεις / APIs

| Script    | API       | Είσοδος | Spark App ID      | Elapsed    |
|-----------|-----------|---------|-------------------|------------|
| q1_rdd.py | RDD       | CSV     | spark-0cc020bd... | 1.410,911s |
| q1_df.py  | DataFrame | CSV     | spark-e55e23dc... | 628,513s   |
| q1_df.py  | DataFrame | Parquet | spark-5c571a79... | 447,276s   |
| q1_sql.py | Spark SQL | Parquet | spark-05e1d5ef... | 122,192s   |

**Table 15:** Q1 – Υλοποιήσεις και χρόνοι εκτέλεσης (πλήρη App IDs στο Παράρτημα)

## 8.7 Βασικά Αποτελέσματα

Top hourly slot:

| Πεδίο                | Τιμή                |
|----------------------|---------------------|
| pickup_date          | 2024-03-28          |
| pickup_hour          | <b>21</b>           |
| weekday              | Thu (Πέμπτη)        |
| time_band            | Evening             |
| trips                | <b>9.431</b>        |
| unique_pickup_zones  | 98                  |
| avg_duration_minutes | 16,6831             |
| avg_trip_distance    | 3,3179 km           |
| avg_total_amount     | \$26,6143           |
| total_revenue        | <b>\$250.999,22</b> |

**Table 16:** Q1 – Top hourly slot

**Time-band summary:**

| Time Band | Ώρες      | Trips (CSV/RDD) | Share           | Trips (Parquet/SQL) | Share           |
|-----------|-----------|-----------------|-----------------|---------------------|-----------------|
| Late      | 22, 23, 0 | 469.947         | <b>68,5862%</b> | 469.945             | <b>68,5861%</b> |
| Evening   | 21        | 215.245         | 31,4138%        | 215.245             | 31,4139%        |

**Table 17:** Q1 – Time-band summary**8.8 Physical/Logical Plan**

- **DF/SQL plans:** Catalyst παράγει Aggregate → Window → Sort → GlobalLimit. Το Parquet plan δείχνει PartitionFilters: [pickup\_day IN (26, 27, 28)] – partition pruning ενεργό.
- **RDD:** Δεν υπάρχει Catalyst plan. Υλοποίηση με manual map/filter/reduceByKey. Το q1\_rdd\_csv\_plan.txt περιέχει σημείωση αντί για physical plan.

**8.9 Caveats**

- Διαφορά 2 rows (685.192 vs 685.190) μεταξύ CSV/RDD και Parquet/SQL: αμελητέα αλλά καταγεγραμμένη.
- Το Late band κυριαρχεί εν μέρει επειδή περιέχει 3 ώρες (22, 23, 0) vs 1 ώρα για Evening (21).

**9. Q2: Διάρκεια, Ταχύτητα και Ενδείξεις Συμφόρησης****9.1 Τι Ζητάει η Εκφώνηση**

Απάντηση στο: *πότε οι διαδρομές είναι πιο αργές ή πιο αναποτελεσματικές; Σύγκριση απόστασης ταξίμετρου (trip\_distance) με ευθεία Haversine απόσταση. Εντοπισμός ενδείξεων συμφόρησης (χαμηλή ταχύτητα, μεγάλη detour\_ratio).*

**9.2 Υποερωτήματα / Ζητούμενα Εκφώνησης**

Για κάθε pickup\_hour υπολογίζω:

- trips, avg\_duration\_minutes, median\_duration\_minutes, p90\_duration\_minutes
- avg\_speed\_kmh, agg\_speed\_kmh, avg\_haversine\_kmh, avg\_distance\_gap\_kmh, avg\_detour\_ratio, congestion\_candidate\_share

Top 5 fastest + top 5 slowest per km (anomaly analysis).

**Haversine formula:**

$$a = \sin^2\left(\frac{\Delta\phi}{2}\right) + \cos\phi_1 \cdot \cos\phi_2 \cdot \sin^2\left(\frac{\Delta\lambda}{2}\right), \quad d = 2R \cdot \arctan\sqrt{\frac{a}{1-a}}, \quad R = 6371 \text{ km}$$

**9.3 Απαιτήσεις Εμπλοκής**

(α) **Υπόθεση.** Βλ. §6.2 – ώρα 0: χαμηλότερη κυκλοφορία, αναμένω υψηλότερη speed. Ώρα 21: αναμένω πιο συμφορημένη.

| Είδος             | trip_distance  | dur. (min) | haversine_km | Ερμηνεία                                  |
|-------------------|----------------|------------|--------------|-------------------------------------------|
| Fastest (anomaly) | ≈18.990.260 km | ≈8,43      | ≈4,20        | Εσφαλμένο trip_distance, αδύνατο φυσικά   |
| Slowest (anomaly) | ≈1,609 km      | ≈25.367    | –            | Undetected timestamp error (≈17,6 ημέρες) |

**Table 18:** Q2 – Ακραίες εγγραφές

(β) **Ακραίες εγγραφές.** Και οι δύο αποτελούν data quality issues, όχι πραγματικές διαδρομές. Δεν αφαιρούνται από τα basic validity filters.

(γ) **UDF vs built-in.** Η Python UDF εμφανίζεται ως PythonUDF στο physical plan – opaque για τον Catalyst. Δεν μπορεί να γίνει expression pushdown ή rewriting εντός της UDF. Οι built-in εκφράσεις (sin, cos, atan2) είναι Catalyst-visible. Ο elapsed UDF (140,9s) είναι ταχύτερος από built-in (190,7s) σε αυτή την εκτέλεση – πιθανώς λόγω cluster state. Η γενική αρχή για optimizer visibility παραμένει ισχυρή ανεξάρτητα από αυτό το single run.

(δ) **Συμπέρασμα.** Η ώρα 21 εμφανίζεται πιο «προβληματική»: τα περισσότερα trips, υψηλότερο congestion\_candidate\_share (0,160), χαμηλότερη μέση Haversine απόσταση (3,44 km). Η μετρική congestion\_candidate\_share (speed\_kmh < 10 AND trip\_distance\_km ≥ 1) στηρίζει καλύτερα το συμπέρασμα.

**9.4 Προσωπικό Φίλτρο**

```
pickup_hour IN (21, 22, 23, 0)    # 2015 dataset
# NYC bounding box:
min_lon = -74.30, max_lon = -73.60
min_lat = 40.45, max_lat = 40.95
```

Τα όρια NYC bounding box επιλέχθηκαν για να καλύψουν Manhattan, Queens, Bronx, Brooklyn, Staten Island και τα airports, ενώ αποκλείουν εγγραφές με μηδενικές ή ακραίες GPS τιμές.

## 9.5 Inputs και Data Quality Filters

- **Dataset:** yellow\_tripdata\_2015
- **Filters:** valid timestamps, duration\_minutes > 0, trip\_distance > 0, non-zero coordinates within bounding box, pickup\_hour IN (21,22,23,0), haversine\_km > 0.2
- **Raw row count:** 12.748.986
- **Filtered row count:** 2.401.620

## 9.6 Υλοποιήσεις / APIs

| Script           | API       | Haversine       | Είσοδος | Spark App ID      | Elapsed    |
|------------------|-----------|-----------------|---------|-------------------|------------|
| q2_df_builtin.py | DataFrame | Built-in        | CSV     | spark-dc403799... | 403,799... |
| q2_df_builtin.py | DataFrame | Built-in        | Parquet | spark-f9190271... | 190,714... |
| q2_df_udf.py     | DataFrame | Python UDF      | Parquet | spark-b5140939... | 140,939... |
| q2_sql.py        | Spark SQL | SQL expressions | Parquet | spark-f6589572... | 589,572... |

**Table 19:** Q2 – Υλοποιήσεις και χρόνοι εκτέλεσης (πλήρη App IDs στο Παράρτημα)

Η DataFrame built-in υλοποίηση εκτελέστηκε δύο φορές: μία σε raw CSV και μία σε prepared Parquet. Η CSV εκτέλεση καλύπτει την απαίτηση CSV input, ενώ η Parquet εκτέλεση χρησιμοποιείται για άμεση σύγκριση με την UDF Parquet εκτέλεση.

## 9.7 Βασικά Αποτελέσματα

Ωριαία περίληψη (built-in):

| Ώρα       | Trips          | Avg Dur. | Median  | P90     | Avg Hav. km | Cong. Share     |
|-----------|----------------|----------|---------|---------|-------------|-----------------|
| <b>21</b> | <b>694.717</b> | 12,4364  | 9,7333  | 21,7500 | 3,4437      | <b>0,160046</b> |
| <b>22</b> | 670.872        | 12,7229  | 9,9667  | 22,1833 | 3,5636      | 0,148787        |
| <b>23</b> | 578.024        | 13,1556  | 10,1333 | 22,9000 | 3,7457      | 0,131996        |
| <b>0</b>  | 458.007        | 13,3723  | 10,0000 | 23,0833 | 3,8012      | 0,113612        |

**Table 20:** Q2 – Ωριαία περίληψη (built-in αποτελέσματα)

Σαφής τάση: καθώς η νύχτα προχωρά, μειώνονται τα trips, αυξάνεται η avg Haversine km, μειώνεται το congestion\_candidate\_share.

## 9.8 Physical/Logical Plan Discussion

Βλ. §15.

- **Built-in CSV plan:** Εμφανίζει FileScan csv – η ανάγνωση γίνεται row-based με runtime casting και normalization των raw TLC columns. Ο Haversine υπολογισμός παραμένει Catalyst-visible (sin, cos, atan2).
- **Built-in Parquet plan:** Εμφανίζει FileScan parquet – διαβάζει ήδη type-d/normalized columns σε columnar format με partition pruning. Ο Haversine υπολογισμός είναι επίσης Catalyst-visible.
- **UDF plan:** PythonUDF[haversine\_km#...] – opaque. Serialization/deserialization JVM ↔ Python εισάγει overhead.
- **SQL plan:** Ισοδύναμο ορατότητας με built-in.

*Σημείωση:* Οι δύο συγκρίσεις είναι διαφορετικές ως προς αντικείμενο: **CSV vs Parquet** = σύγκριση μορφής εισόδου (input format overhead) · **Built-in vs UDF** = σύγκριση optimizer visibility. Η built-in CSV και η built-in Parquet έκδοση απομονώνουν το input-format overhead, ενώ η built-in Parquet και η UDF Parquet απομονώνουν το UDF overhead.

## 10. Q3: Έσοδα, Απόδοση Διαδρομών και Ζώνες Υψηλής Οικονομικής Σημασίας

### 10.1 Τι Ζητάει η Εκφώνηση

Απάντηση στο: ποιοι τύποι διαδρομών και ποιες ζώνες παράγουν τα περισσότερα έσοδα ή την υψηλότερη απόδοση; Διάκριση total revenue από efficiency. Ελάχιστο support threshold για αξιόπιστη κατάταξη. Σύγκριση partition pruning vs no-pruning.

### 10.2 Απαιτήσεις Εμπλοκής

(α) **Total revenue vs efficiency.** Το JFK Airport/long βρίσκεται πρώτο σε total\_revenue λόγω υψηλού volume μακρινών διαδρομών. Ωστόσο, το JFK/very\_short είναι πρώτο σε revenue\_per\_mile και revenue\_per\_minute. Αυτό συμβαίνει επειδή τα fixed charges (airport\_fee \$1,75, congestion\_surcharge \$2,50) κυριαρχούν σε πολύ σύντομες διαδρομές, ανεβάζοντας τεχνητά τις efficiency metrics. Η επιχειρησιακή αξία τους είναι αμφίβολη.

(β) **Μικρά δείγματα.** Χωρίς `support threshold = 50`, ζώνες με 5–10 trips μπορεί να έχουν `extreme revenue_per_mile`. Με `threshold = 50`, μόνο ζώνες με επαρκή evidence εμφανίζονται στα rankings. Παράδειγμα: JFK/very\_short με 441 trips – αξιόπιστο. Μία υποθετική ζώνη με 3 trips – όχι.

### (γ) CSV vs Parquet και partition pruning.

- DF CSV (568,9s) → DF Parquet normal (316,3s): speedup  $\approx 1,8\times$
- DF Parquet no-pruning (229,9s): ταχύτερο από normal Parquet σε αυτό το run (βλ. §15 για εξήγηση).
- SQL Parquet (107,9s): ταχύτερο όλων.
- Normal Parquet plan: `PartitionFilters: [pickup_day IN (26,27,28)]` – pruning ενεργό.
- No-pruning plan: `Filter: dayofmonth(cast(pickup_ts as date)) ...`

(δ) **Διαγράμματα.** `q3_top_zones_total_revenue.png`, `q3_top_zones_revenue_per_minute.png`

## 10.3 Inputs και Φίλτρα

- **Datasets:** `yellow_tripdata_2024` (CSV + Parquet) JOIN `taxi_zone_lookup`
- **Filters:** `duration_minutes > 0, trip_distance > 0, fare_amount > 0, total_amount > 0, personalized days/hours`
- **Support threshold:** `trips >= 50`
- **Distance buckets:** `very_short (<1), short (1–3), medium (3–10), long ( $\geq 10$ ) [miles]`
- **Filtered rows:** CSV = 682.561 | Parquet = 682.559

## 10.4 Υλοποιήσεις / APIs

| Script                 | API       | Είσοδος            | Spark App ID                   | Elapsed  |
|------------------------|-----------|--------------------|--------------------------------|----------|
| <code>q3_df.py</code>  | DataFrame | CSV                | <code>spark-a7d53e51...</code> | 568,984s |
| <code>q3_df.py</code>  | DataFrame | Parquet (normal)   | <code>spark-183e7387...</code> | 316,275s |
| <code>q3_df.py</code>  | DataFrame | Parquet (no-prune) | <code>spark-84bd661d...</code> | 229,864s |
| <code>q3_sql.py</code> | Spark SQL | Parquet            | <code>spark-abdf683b...</code> | 107,972s |

**Table 21:** Q3 – Υλοποιήσεις και χρόνοι εκτέλεσης

## 10.5 Βασικά Αποτελέσματα

| Μετρική            | Zone        | Borough | Bucket     | Trips  | Τιμή                  |
|--------------------|-------------|---------|------------|--------|-----------------------|
| Top total_revenue  | JFK Airport | Queens  | long       | 36.302 | <b>\$3.265.402,20</b> |
| Top revenue/mile   | JFK Airport | Queens  | very_short | 441    | <b>\$134,8672</b>     |
| Top revenue/minute | JFK Airport | Queens  | very_short | 441    | <b>\$19,9045</b>      |

**Table 22:** Q3 – Βασικά αποτελέσματα (top-1 ανά μετρική)

## 11. Q4: Τρόπος Πληρωμής και Συμπεριφορά Φιλοδωρήματος

### 11.1 Τι Ζητάει η Εκφώνηση

Απάντηση στο: πώς διαφοροποιούνται οι διαδρομές ανά τρόπο πληρωμής και τι μπορούμε, με προσοχή, να πούμε για τα φιλοδωρήματα; Περιγραφικό ερώτημα – **δεν** αποδεικνύει αιτιακή σχέση.

### 11.2 Απαιτήσεις Εμπλοκής

(α) Προσεκτική ερμηνεία φιλοδωρημάτων. Δεν πρέπει να συμπεράνουμε ότι «οι επιβάτες με κάρτα δίνουν περισσότερα φιλοδωρήματα» για τους εξής λόγους:

1. Τα cash tips δεν καταγράφονται στο πεδίο `tip_amount` – καταγράφονται μόνο ηλεκτρονικές συναλλαγές.
2. Η μηδενική τιμή `tip_amount` για cash payments είναι artifact του reporting system, όχι ένδειξη ότι δεν δόθηκε tip.
3. Η σύγκριση card vs cash tip rate δεν ελέγχει για απόσταση, ώρα, ζώνη ή άλλες μεταβλητές. Πρόκειται για descriptive finding, όχι causal analysis.

(β) Ώρες και πληρωμές.

- Υψηλότερο `card_share`: Ώρα **00:00** (0,877259)
- Χαμηλότερο `card_share`: Ώρα **21:00** (0,868096)
- Διαφορά  $\approx 0,9\%$  – μικρή αλλά consistent. Η ώρα 0 (nightlife returns, airport) εμφανίζει υψηλότερο card share, συμβατό με την υπόθεση.

| Vendor   | Card Share |
|----------|------------|
| Vendor 1 | 0,869082   |
| Vendor 2 | 0,871938   |

**Table 23:** Q4 – Card share ανά vendor

(γ) **Πάροχοι.** Η εικόνα είναι παρόμοια μεταξύ vendors. Δεν αποδίδεται αιτία.

(δ) **Διαγράμματα.** q4\_card\_share\_by\_hour.png, q4\_avg\_tip\_rate\_card\_by\_hour.png

### 11.3 Βασικά Αποτελέσματα

| Μετρική                 | Τιμή                   |
|-------------------------|------------------------|
| Card share range        | 86,8%–87,7%            |
| Avg card tip rate range | ≈24,2%–25,2%           |
| Cash tip rate           | ≈0% (δεν καταγράφεται) |
| Max card share ώρα      | 00:00 (0,877259)       |
| Min card share ώρα      | 21:00 (0,868096)       |

**Table 24:** Q4 – Κύριες μετρικές

### 11.4 Υλοποιήσεις / APIs

| Script    | API       | Είσοδος | App ID            | Elapsed    |
|-----------|-----------|---------|-------------------|------------|
| q4_df.py  | DataFrame | Parquet | spark-20abfd23... | 160,937s   |
| q4_sql.py | Spark SQL | CSV     | spark-5d58d6e9... | 3.313,016s |
| q4_sql.py | Spark SQL | Parquet | spark-cdfe89bd... | 1.000,471s |

**Table 25:** Q4 – Υλοποιήσεις

## 12. Q5: Αεροδρόμια και Ροές Μεταξύ Δήμων

### 12.1 Τι Ζητάει η Εκφώνηση

Απάντηση στο: τι ρόλο παίζουν τα αεροδρόμια και οι ροές μεταξύ δήμων; Διπλή συνένωση (join) με taxi\_zone\_lookup για pu\_/do\_ zones. Σύγκριση airport vs non-airport διαδρομών. Σύγκριση join strategies.

## 12.2 Απαιτήσεις Εμπλοκής

(α) **Ορισμός αεροδρομίου.** Ζώνη ταξινομείται ως αεροδρόμιο εάν:

1. Το zone name περιέχει “JFK”, “LaGuardia”, “Newark” ή “Airport”, ή
2. Borough = “EWR”.

Επιπλέον, `airport_fee > 0` χρησιμοποιείται ως ένδειξη pickup από αεροδρόμιο. Παραδείγματα: JFK Airport (Queens), LaGuardia Airport (Queens), Newark Airport (EWR).

(β) **Ροές.** Manhattan→Manhattan κυριαρχεί (80,9%) – κυρίως ενδοδημοτικές ροές. Η δεύτερη ροή σε volume (Queens→Manhattan) έχει 94% `airport_trip_share` – σχεδόν αποκλειστικά airport-based.

| Μετρική            | Airport Routes | Intra-Manhattan |
|--------------------|----------------|-----------------|
| Avg total_amount   | \$80–\$126     | ≈\$25           |
| Avg trip_distance  | ≈21 km         | ≈3 km           |
| Avg duration (min) | ≈35            | ≈16             |

**Table 26:** Q5 – Σύγκριση airport vs intra-Manhattan

(γ) **Αεροδρομιακές vs υπόλοιπες διαδρομές.** Σαφής διαφορά και στις τρεις μετρικές.

(ε) **Οπτικοποίηση.** `q5_borough_flow_heatmap_trips.png`, `q5_top_borough_flows_1.png`, `q5_top_airport_routes_by_trips.png`, `q5_top_airport_routes_by_avg_amount.png`

## 12.3 Βασικά Αποτελέσματα

**Borough flows:**

| Ροή                 | Trips          | Trip Share      | Total Revenue   |
|---------------------|----------------|-----------------|-----------------|
| Manhattan→Manhattan | <b>554.348</b> | <b>0,809043</b> | \$12.060.397,47 |
| Queens→Manhattan    | 40.005         | —               | —               |

**Table 27:** Q5 – Borough flows

**Top airport route (JFK → Outside of NYC):**

| Μετρική              | Τιμή              |
|----------------------|-------------------|
| Trips                | 2.071             |
| Avg total_amount     | <b>\$126,4984</b> |
| Avg trip_distance    | 21,3380 km        |
| Avg duration_minutes | 35,4897           |

**Table 28:** Q5 – Top airport route

## 12.4 Υλοποιήσεις / APIs

| Script    | API       | Variant      | App ID            | Elapsed  |
|-----------|-----------|--------------|-------------------|----------|
| q5_df.py  | DataFrame | Default join | spark-96c85865... | 54,649s  |
| q5_df.py  | DataFrame | No-broadcast | spark-7a2b32a2... | 65,593s  |
| q5_sql.py | Spark SQL | Parquet      | spark-9a871dee... | 103,191s |

**Table 29:** Q5 – Υλοποιήσεις

## 13. Q6: Ανισορροπία Επιβιβάσεων και Αποβιβάσεων ανά Ζώνη

### 13.1 Τι Ζητάει η Εκφώνηση

Απάντηση στο: σε ποιες ζώνες φαίνεται να υπάρχει πλεόνασμα επιβιβάσεων ή αποβιβάσεων; Full outer join pickups/dropoffs, normalized imbalance metric, activity threshold. Descriptive measurement – όχι prediction.

**Imbalance formulas:**

$$\text{net\_pickups} = \text{pickups} - \text{dropoffs}$$

$$\text{imbalance\_ratio} = \frac{\text{pickups} - \text{dropoffs}}{\text{pickups} + \text{dropoffs}}$$

$$\text{activity} = \text{pickups} + \text{dropoffs} \quad [\text{threshold: activity} \geq 30]$$

### 13.2 Απαιτήσεις Εμπλοκής

(α) Δύο μετρικές, δύο ερμηνείες.

- `net_pickups`: Απόλυτη ανισορροπία – ευνοεί ζώνες με μεγάλο volume. JFK έχει υψηλό `net_pickups` επειδή έχει πολλές διαδρομές. Χρήσιμο για fleet management (πόσα ταξί χρειάζονται).

- **imbalance\_ratio**: Κανονικοποιημένη ανισορροπία ανεξάρτητα από volume. LaGuardia έχει υψηλότερο ratio (0,963) από JFK (0,904) ενώ έχει λιγότερες διδρομές. Χρήσιμο για zone characterization (πόσο one-sided είναι η ζώνη).

**(β) Επιχειρησιακή ερμηνεία. Ζώνες με θετικό net\_pickups (pickup-surplus):**

- **JFK Airport (ώρα 22)**: net\_pickups = 11.834. Οι επιβάτες φεύγουν από τη ΝΥ προς το αεροδρόμιο. Για dispatchers: διαθεσιμότητα οχημάτων γύρω από JFK μπορεί να είναι χαμηλή post-22:00.
- **LaGuardia Airport (ώρα 21)**: ratio = 0,963. Σχεδόν αποκλειστικά pickups. Παρόμοιο με JFK.
- **Midtown Manhattan zones**: Θετικό net λόγω εξόδων/εστιατόρια.

**Ζώνες με αρνητικό net\_pickups (dropoff-surplus):**

- **Upper East Side North (ώρα 22)**: net\_pickups = -3.448. Residential περιοχή, ο κόσμος επιστρέφει από βραδινή έξοδο. Για dispatchers: περίσσεια ταξί μετά τα dropoffs.
- **Upper West Side**: Παρόμοιο pattern – residential returns.
- **Yorkville**: Residential Manhattan – dropoff-surplus.

**(ε) Συμπέρασμα.** Αεροδρόμια (JFK, LaGuardia) εμφανίζουν pickup-surplus, ειδικά στις ώρες 21–22. Manhattan residential zones εμφανίζουν dropoff-surplus καθώς ο κόσμος επιστρέφει. Η ώρα 22 έχει τα υψηλότερα total\_abs\_net\_pickups (117.804), ενώ η ώρα 21 έχει το υψηλότερο mean\_abs\_imbalance\_ratio (0,547).

### 13.3 Βασικά Αποτελέσματα

| Zone                             | Bor.      | Hr. | Pickups | Dropoffs | Net           | Ratio            |
|----------------------------------|-----------|-----|---------|----------|---------------|------------------|
| <i>Top positive net_pickups:</i> |           |     |         |          |               |                  |
| JFK Airport                      | Queens    | 22  | 12.461  | 627      | <b>11.834</b> | <b>0,904187</b>  |
| <i>Top negative net_pickups:</i> |           |     |         |          |               |                  |
| Upper East Side N                | Manhattan | 22  | 3.296   | 6.744    | <b>-3.448</b> | <b>-0,343426</b> |
| <i>Top abs imbalance_ratio:</i>  |           |     |         |          |               |                  |
| LaGuardia Airport                | Queens    | 21  | 6.866   | 131      | 6.735         | <b>0,962555</b>  |

**Table 30:** Q6 – Βασικά αποτελέσματα imbalance

**Ωριαία σύνοψη:**

| Όρα       | Total Abs Net Pickups | Mean Abs Imbalance Ratio |
|-----------|-----------------------|--------------------------|
| 21        | 114.995               | <b>0,546616</b>          |
| <b>22</b> | <b>117.804</b>        | 0,531298                 |
| 23        | 103.198               | 0,540239                 |
| 0         | 75.525                | 0,536443                 |

Table 31: Q6 – Ωριαία σύνοψη ανισορροπίας

### 13.4 Υλοποιήσεις / APIs

| Script    | API       | App ID            | Elapsed  |
|-----------|-----------|-------------------|----------|
| q6_df.py  | DataFrame | spark-fe2b06fb... | 81,587s  |
| q6_sql.py | Spark SQL | spark-49ed2828... | 186,761s |

Table 32: Q6 – Υλοποιήσεις

## 14. Q6 OD-Halves: Πείραμα Κλιμάκωσης Εκτελεστών

### 14.1 Στόχος και Σχεδιασμός

**Ξεχωριστό ερώτημα** – δεν συγχέεται με το personalized Q6 imbalance.

Σύγκριση μήτρας OD (Origin-Destination) μεταξύ πρώτου (H1) και δεύτερου (H2) ημιμήνου 2024, με scaling experiment σε 3 executor configurations.

```

Dataset:          Full valid 2024 data (xwris personalization)
Validity filters: duration_minutes > 0, trip_distance > 0,
                  fare_amount > 0
valid_row_count:  39.704.240

H1: pickup_day <= 15
H2: pickup_day > 15

Grouping keys:    (pu_location_id, do_location_id, pickup_hour)
min_trips_h1/h2:  30
Inner join H1 x H2 on grouping keys
compared_pair_count: 62.100

```

## 14.2 Executor Configurations

| Config | Executors | Cores/Executor | Memory/Executor |
|--------|-----------|----------------|-----------------|
| A      | 2         | 2              | 2G              |
| B      | 4         | 2              | 2G              |
| C      | 8         | 2              | 2G              |

**Table 33:** OD-Halves – Executor configurations

## 14.3 Runtimes (Cold / Warm)

| Config | App ID (Cold)     | Cold (s)       | App ID (Warm)     | Warm (s)       |
|--------|-------------------|----------------|-------------------|----------------|
| A      | spark-59d4a6f6... | <b>355,798</b> | spark-9546f228... | <b>225,216</b> |
| B      | spark-dddc36e3... | <b>133,326</b> | spark-1dbd0e8a... | <b>120,434</b> |
| C      | spark-0aba698d... | <b>100,972</b> | spark-0c230232... | <b>88,189</b>  |

**Table 34:** OD-Halves – Cold/Warm runtimes

## 14.4 Ερμηνεία Scaling και Caching

### Scaling:

- A → B (2→4 executors): cold −62,5% (355,8 → 133,3s). Σαφής βελτίωση.
- B → C (4→8 executors): cold −24,3% (133,3 → 101,0s). Μικρότερη βελτίωση.
- Η κλιμάκωση είναι **υπογραμμική** – αναμενόμενο λόγω shuffle overhead, Sort-MergeJoin stages, Amdahl’s law.

### Cold vs Warm:

- Config A: 355,8s → 225,2s (κέρδος 37%). Μεγάλη διαφορά – σημαντικό caching benefit.
- Config B: 133,3s → 120,4s (κέρδος 10%).
- Config C: 101,0s → 88,2s (κέρδος 13%).

Τα warm runs είναι ταχύτερα κυρίως λόγω `InMemoryRelation` – δεδομένα cached στη μνήμη των executors. Η cold/warm σύγκριση δεν αποδίδεται αποκλειστικά σε executor count, επειδή το caching επηρεάζει επίσης το αποτέλεσμα.

**Στατιστική ισχύς:** Κάθε config έχει μόνο 1 cold και 1 warm run. Το scaling trend είναι σαφές, αλλά τα exact absolute times έχουν uncertainty.

## 14.5 Βασικά OD Αποτελέσματα

| <i>Top Increase H1→H2:</i> |        |      |          |          |            |
|----------------------------|--------|------|----------|----------|------------|
| pu_loc                     | do_loc | hour | trips_h1 | trips_h2 | change_pct |
| 113                        | 255    | 18   | 35       | 103      | +194,29%   |
| <i>Top Decrease H1→H2:</i> |        |      |          |          |            |
| 246                        | 232    | 13   | 95       | 33       | −65,26%    |

**Table 35:** OD-Halves – Top increase/decrease H1→H2

## 15. Μελέτη Catalyst και Φυσικών Σχεδίων Εκτέλεσης

### 15.1 Q1 – CSV vs Parquet Scan

- **DF/SQL CSV:** `FileScan csv` – full CSV read, string parsing overhead.
- **DF/SQL Parquet:** `FileScan parquet PartitionFilters: [pickup_day IN (26,27,28)]` – columnar read + partition pruning.
- **RDD:** Δεν υπάρχει Catalyst plan. Υλοποίηση: `textFile → map(parse_row) → filter → reduceByKey`. Το `q1_rdd_csv_plan.txt` περιέχει σχόλιο, όχι physical plan.

### 15.2 Q2 – Built-in vs Python UDF

Υπάρχουν δύο built-in runs: ένα σε CSV και ένα σε Parquet.

- **Built-in CSV** (`q2_df_builtin_csv_plan.txt`): `FileScan csv` – Catalyst-visible Haversine, αλλά με CSV parsing/casting overhead.
- **Built-in Parquet** (`q2_df_builtin_plan.txt`): `FileScan parquet` – Catalyst-visible Haversine, typed columns, columnar I/O.
- **Python UDF** (`q2_df_udf_plan.txt`): Εμφανίζεται ως `PythonUDF[haversine_km#...` – **opaque** για τον Catalyst. Δεν μπορεί να γίνει expression rewriting ή pushdown εντός της UDF.
- **SQL** (`q2_sql_plan.txt`): Ισοδύναμο ορατότητας με built-in.

Η **καθαρή σύγκριση για input format** είναι built-in CSV (401,8s) vs built-in Parquet (190,7s): speedup  $\approx 2,11\times$ , αντανακλά αποκλειστικά το κόστος μορφής εισόδου.

Η **καθαρή σύγκριση για UDF overhead** είναι built-in Parquet (190,7s) vs UDF Parquet (140,9s): το UDF εμφανίστηκε ταχύτερο σε αυτό το single run. Αυτό δεν αναιρεί ότι η UDF είναι opaque για τον Catalyst – ο runtime επηρεάζεται και από cluster

state, data locality. Ένα μόνο run ανά παραλλαγή δεν αρκεί για στατιστικά ισχυρό συμπέρασμα.

### 15.3 Q3 – Partition Pruning

- **Normal Parquet** (`pickup_day IN (26,27,28)`):

```
PartitionFilters: [pickup_day#N IN (26,27,28)]
```

Ο Spark φορτώνει μόνο τα partition directories `pickup_day=26/27/28`.

- **No-pruning** (`dayofmonth(cast(pickup_ts as date)) IN (26,27,28)`):

```
Filter: (dayofmonth(cast(pickup_ts#N as date)) IN (26,27,28))
```

Δεν αναφέρεται απευθείας στη partition column. Φορτώνει όλα τα data files.

*Runtime caveat:* Το no-pruning run (229,9s) είναι ταχύτερο από το normal Parquet (316,3s) σε αυτό το pair. Πιθανή εξήγηση: cluster caching ή state. Δεν αντιφάσκει με τη γενική αρχή – ένα single run pair δεν είναι στατιστικά ισχυρό.

### 15.4 Q4 – Conditional Aggregation

Η κεντρική aggregation χρησιμοποιεί:

```
CASE WHEN payment_type = 1 THEN tip_amount ELSE 0.0 END
```

Πλήρως ορατή στον Catalyst ως conditional aggregation.

### 15.5 Q5 – Double Lookup Join και Broadcast

- **Default plan:** Δύο BroadcastHashJoin με `taxi_zone_lookup` (265 rows). Ο Spark επιλέγει broadcast αυτόματα λόγω μικρού μεγέθους ( $\ll$  `autoBroadcastJoinThreshold` 10MB).
- **No-broadcast plan:** `NO_BROADCAST` hint. Elapsed: 65,6s vs 54,6s –  $\approx 20\%$  overhead.

### 15.6 Q6 – Full Outer Join και OD-Halves

- **DF plan:** `filter`  $\rightarrow$  `pickup_agg`  $\rightarrow$  `dropoff_agg`  $\rightarrow$  FullOuter join  $\rightarrow$  `coalesce`  $\rightarrow$  imbalance metrics  $\rightarrow$  LeftOuter join with zones.
- **SQL plan:** CTEs: `filtered_trips`  $\rightarrow$  `pickup_agg`  $\rightarrow$  `dropoff_agg`  $\rightarrow$  combined (FULL OUTER JOIN)  $\rightarrow$  `with_metrics`. Ο Catalyst βλέπει τη full pipeline.
- **OD-Halves Cold:** SortMergeJoin για inner join  $H1 \bowtie H2$ . AdaptiveSparkPlan – AQE ενεργό.

- **OD-Halves Warm:** `InMemoryRelation` – evidence caching.

## 16. Performance και Scaling Discussion

### 16.1 RDD vs DataFrame vs SQL (Q1)

| Υλοποίηση | Είσοδος | Elapsed       | Speedup vs RDD |
|-----------|---------|---------------|----------------|
| RDD       | CSV     | 1.410,9s      | 1× (baseline)  |
| DataFrame | CSV     | 628,5s        | 2,2×           |
| DataFrame | Parquet | 447,3s        | 3,2×           |
| SQL       | Parquet | <b>122,2s</b> | <b>11,5×</b>   |

**Table 36:** Q1 – Σύγκριση RDD/DataFrame/SQL

Η τάξη μεγέθους RDD vs SQL Parquet ( $\approx 11,5\times$ ) αντανακλά: (a) Catalyst optimization, (b) columnar I/O + partition pruning, (c) αποφυγή manual parsing overhead.

### 16.2 CSV vs Parquet

| Query          | CSV Elapsed | Parquet Elapsed | Speedup |
|----------------|-------------|-----------------|---------|
| Q1 DF          | 628,5s      | 447,3s          | 1,40×   |
| Q2 DF built-in | 401,8s      | 190,7s          | 2,11×   |
| Q3 DF          | 568,9s      | 316,3s          | 1,80×   |
| Q4 SQL         | 3.313,0s    | 1.000,5s        | 3,31×   |

**Table 37:** CSV vs Parquet – σύγκριση elapsed time

Parquet είναι σταθερά ταχύτερο. Το Q4 SQL CSV (3.313s) είναι ακραία αργό – CSV parsing overhead σε full 2024 dataset χωρίς partitioning. Στο Q2, το CSV input είναι πιο βαρύ επειδή γίνεται ανάγνωση row-based text format και normalization/casting των raw TLC columns κατά την εκτέλεση. Το Parquet input είναι ήδη prepared με typed columns και columnar storage. Επομένως η σύγκριση Q2 DF built-in CSV vs Parquet απομονώνει κυρίως το κόστος μορφής εισόδου.

### 16.3 UDF vs Built-in (Q2)

| Variant       | Elapsed       | Catalyst Visibility |
|---------------|---------------|---------------------|
| DF built-in   | 190,7s        | Πλήρης              |
| <b>DF UDF</b> | <b>140,9s</b> | Opaque (PythonUDF)  |
| SQL           | 589,8s        | Πλήρης              |

**Table 38:** Q2 – UDF vs built-in

### 16.4 Broadcast vs No-broadcast (Q5)

| Variant             | Elapsed |
|---------------------|---------|
| Default (broadcast) | 54,6s   |
| No-broadcast        | 65,6s   |

**Table 39:** Q5 – Broadcast vs no-broadcast

Broadcast  $\approx 20\%$  ταχύτερο – επιβεβαιώνει την αξία για μικρά lookup tables.

### 16.5 OD-Halves Scaling

| Config     | Cold (s) | Warm (s) | Cold Speedup vs A |
|------------|----------|----------|-------------------|
| A (2 exec) | 355,8    | 225,2    | 1×                |
| B (4 exec) | 133,3    | 120,4    | 2,67×             |
| C (8 exec) | 101,0    | 88,2     | <b>3,52×</b>      |

**Table 40:** OD-Halves – Scaling summary

Από A→C (4× executors): 3,52× speedup – υπογραμμική κλιμάκωση λόγω shuffle/join overhead.

## 17. Reproducibility / RUNBOOK Summary

Πλήρης τεκμηρίωση στο RUNBOOK.md του repository. Σύντομα βήματα:

```
source ~/bigdata-env.sh      # Setup environment
cd ~/project2026-bigdata
```

```
# Data preparation
./project2026/scripts/run_prepare_parquet.sh

# EDA
./project2026/scripts/run_eda.sh

# Q1-Q6 (see RUNBOOK.md for full commands)
./project2026/scripts/run_q1_RDD.sh
./project2026/scripts/run_q1_SQL_Par.sh
# ...

# Q2 (built-in runs CSV Parquet, UDF, SQL)
./project2026/scripts/run_q2_DF_Builtin_CSV.sh
./project2026/scripts/run_q2_DF_Builtin.sh
./project2026/scripts/run_q2_DF_UDF.sh
./project2026/scripts/run_q2_SQL.sh
#      .:      built-in      CSV
      Parquet      runners.

# Q6 OD-Halves (cold + warm per config)
./project2026/scripts/run_q6_OD_A.sh # cold, then warm
./project2026/scripts/run_q6_OD_B.sh
./project2026/scripts/run_q6_OD_C.sh
```

**Ενδεικτικοί χρόνοι:** Prepare Parquet  $\approx 56$  min, EDA  $\approx 67$  min, Q1 SQL Parquet  $\approx 2$  min, Q6 OD Config C warm  $\approx 1,5$  min.

## 18. Limitations και Data Quality Caveats

---

### Data Quality:

- 56 wrong-year 2024 rows: απορρίφθηκαν. Downstream count: 41.169.664.
- $\approx 10\%$  null rate σε surcharge/fee fields – nulls αντιμετωπίζονται ως 0.
- Αρνητικά total\_amount: εξαιρούνται από validity filters.
- Extreme outliers στο Q2 (fastest/slowest anomalies).

### Interpretation Caveats:

- Q4: Descriptive only. Cash tips δεν καταγράφονται.
- Q5: Airport detection βασίζεται σε heuristics.

- Q6: Activity threshold = 30 είναι υποκειμενικό.
- Partition pruning: ένα run pair δεν αποδεικνύει general rule.
- Scaling: μόνο 2 runs (cold/warm) ανά config – χωρίς robust variance.

## Παράρτημα

### A. Λίστα Scripts

| Script             | Σκοπός                                                    |
|--------------------|-----------------------------------------------------------|
| common.py          | SparkSession, personalization, HDFS paths, Timer, schemas |
| prepare_parquet.py | CSV → Parquet conversion με metrics                       |
| eda.py             | Full-year EDA                                             |
| q1_rdd.py          | Q1 RDD API                                                |
| q1_df.py           | Q1 DataFrame (CSV + Parquet)                              |
| q1_sql.py          | Q1 Spark SQL (Parquet)                                    |
| q2_df_builtin.py   | Q2 DataFrame built-in Haversine                           |
| q2_df_udf.py       | Q2 DataFrame Python UDF Haversine                         |
| q2_sql.py          | Q2 Spark SQL                                              |
| q3_df.py           | Q3 DataFrame (CSV + Parquet + no-pruning)                 |
| q3_sql.py          | Q3 Spark SQL (Parquet)                                    |
| q4_df.py           | Q4 DataFrame (Parquet)                                    |
| q4_sql.py          | Q4 Spark SQL (CSV + Parquet)                              |
| q5_df.py           | Q5 DataFrame (default + no-broadcast)                     |
| q5_sql.py          | Q5 Spark SQL (Parquet)                                    |
| q6_df.py           | Q6 DataFrame imbalance (Parquet)                          |
| q6_sql.py          | Q6 Spark SQL imbalance (Parquet)                          |
| q6_od_halves.py    | Q6 OD-Halves scaling experiment                           |
| plot_q3.py         | Q3 plots                                                  |
| plot_q4.py         | Q4 plots                                                  |
| plot_q5.py         | Q5 plots                                                  |
| plot_q6.py         | Q6 plots                                                  |

**Table 41:** Πλήρης λίστα scripts

### B. Spark Application IDs

| Job             | Variant    | Spark App ID                           | Elapsed (s) |
|-----------------|------------|----------------------------------------|-------------|
| Prepare Parquet | –          | spark-614263c24d01428d9e27686116391b3b | 3.329,443   |
| EDA             | Parquet    | spark-7055d17eb1074174a68bf1a8e581be7a | 4.011,758   |
| Q1 RDD          | CSV        | spark-0cc020bd647741729e8f0467659d5cba | 1.410,911   |
| Q1 DF           | CSV        | spark-e55e23dc54854c969da2f5e5ba3a98a7 | 628,513     |
| Q1 DF           | Parquet    | spark-5c571a7967b8471588d7e7e0f63de27b | 447,276     |
| Q1 SQL          | Parquet    | spark-05e1d5eff3e443b88a2e790589b39224 | 122,192     |
| Q2 DF built-in  | CSV        | spark-dcb33cd1ca8c4ceca7f80a7663dc69d2 | 401,799     |
| Q2 DF built-in  | Parquet    | spark-f963a23942c34629b49ee7e36e60f8d0 | 190,714     |
| Q2 DF UDF       | Parquet    | spark-b552a3669292466782e2f242bd82b39c | 140,939     |
| Q2 SQL          | Parquet    | spark-f68dcb130ce54db5add75c78e7087a14 | 589,772     |
| Q3 DF           | CSV        | spark-a7d53e51ee8e4813b567f158f63dbf33 | 568,984     |
| Q3 DF           | Parquet    | spark-183e73870a1b4005896f12e7b8f615fd | 316,275     |
| Q3 DF           | no-pruning | spark-84bd661d42e1404e8c1f80b95b4daad1 | 229,864     |
| Q3 SQL          | Parquet    | spark-abdf683bf4c34101935e3099c6d417d2 | 107,972     |
| Q4 DF           | Parquet    | spark-20abfd23d91b4177a570daeb56b87d6a | 160,937     |
| Q4 SQL          | CSV        | spark-5d58d6e9690b4d67b3d8fb966073644b | 3.313,016   |
| Q4 SQL          | Parquet    | spark-cdfe89bd318e48dc8a582a57f908342d | 1.000,471   |
| Q5 DF           | default    | spark-96c8586594b9460caeca2980c5152f78 | 54,649      |

| Job     | Variant      | Spark App ID                           | Elapsed (s) |
|---------|--------------|----------------------------------------|-------------|
| Q5 DF   | no-broadcast | spark-7a2b32a25a794a479140bfa93a18e8b0 | 65,593      |
| Q5 SQL  | Parquet      | spark-9a871dee8c524e6f9d527516e52dd2aa | 103,191     |
| Q6 DF   | Parquet      | spark-fe2b06fb42ed49a69e37ef6698548fc8 | 81,587      |
| Q6 SQL  | Parquet      | spark-49ed2828358e4097a6c16a65b1f4bfd6 | 186,761     |
| Q6 OD A | cold         | spark-59d4a6f6d1f741738160af228422652e | 355,798     |
| Q6 OD A | warm         | spark-9546f228b19d4dac812ee6df71cc90eb | 225,216     |
| Q6 OD B | cold         | spark-dddc36e3bf8645c8b3d3c0f5fb6e6aed | 133,326     |
| Q6 OD B | warm         | spark-1dbd0e8ab4ad4be382b18a2493f235ae | 120,434     |
| Q6 OD C | cold         | spark-0aba698d1b5f4cc88930b15b4dbd1e63 | 100,972     |
| Q6 OD C | warm         | spark-0c230232d06d4039981bdecc24f0aa4b | 88,189      |

### C. Λίστα Plan Files (27 αρχεία)

q1\_df\_csv\_plan.txt, q1\_df\_parquet\_plan.txt, q1\_rdd\_csv\_plan.txt\*,  
q1\_sql\_parquet\_plan.txt, q2\_df\_builtin\_csv\_plan.txt, q2\_df\_builtin\_plan.txt,  
q2\_df\_udf\_plan.txt, q2\_sql\_plan.txt, q3\_df\_csv\_plan.txt, q3\_df\_parquet\_plan.txt,  
q3\_df\_parquet\_no\_pruning\_plan.txt, q3\_sql\_parquet\_plan.txt,  
q4\_df\_parquet\_plan.txt, q4\_sql\_csv\_plan.txt, q4\_sql\_parquet\_plan.txt,  
q5\_df\_parquet\_plan.txt, q5\_df\_parquet\_no\_broadcast\_plan.txt,  
q5\_sql\_parquet\_plan.txt, q6\_df\_parquet\_plan.txt, q6\_sql\_parquet\_plan.txt,  
q6\_od\_halves\_configA\_cold\_plan.txt, q6\_od\_halves\_configA\_warm\_plan.txt,  
q6\_od\_halves\_configB\_cold\_plan.txt, q6\_od\_halves\_configB\_warm\_plan.txt,  
q6\_od\_halves\_configC\_cold\_plan.txt, q6\_od\_halves\_configC\_warm\_plan.txt

\*RDD plan file: RDD API δεν παράγει logical/physical Catalyst plan.

## D. HDFS Paths

```
Base: hdfs://hdfs-namenode.default.svc.cluster.local:9000
      /user/ipelekanos/project2026

Input (raw CSV):
  /data/yellow_tripdata_2015.csv
  /data/yellow_tripdata_2024.csv
  /data/taxi_zone_lookup.csv

Parquet:
  /user/ipelekanos/project2026/data/parquet/yellow_tripdata_2015/
  /user/ipelekanos/project2026/data/parquet/yellow_tripdata_2024/
  /user/ipelekanos/project2026/data/parquet/taxi_zone_lookup/

Results:
  /user/ipelekanos/project2026/results/metrics/*.json
  /user/ipelekanos/project2026/results/plans/*.txt
  /user/ipelekanos/project2026/results/tables/q1/...
  /user/ipelekanos/project2026/results/tables/q2/
    df_builtin_csv_by_hour
  /user/ipelekanos/project2026/results/tables/q2/
    df_builtin_csv_fastest
  /user/ipelekanos/project2026/results/tables/q2/
    df_builtin_csv_slowest_per_km
  /user/ipelekanos/project2026/results/tables/q2/
    df_builtin_by_hour
  /user/ipelekanos/project2026/results/tables/q2/
    df_builtin_fastest
  /user/ipelekanos/project2026/results/tables/q2/
    df_builtin_slowest_per_km
  /user/ipelekanos/project2026/results/tables/q2/... (df_udf_*,
    sql_*)
  /user/ipelekanos/project2026/results/tables/q3/...
  /user/ipelekanos/project2026/results/tables/q4/...
  /user/ipelekanos/project2026/results/tables/q5/...
  /user/ipelekanos/project2026/results/tables/q6/...

Event Logs:
  /user/ipelekanos/logs/
```

## E. Λίστα Plots (21 αρχεία)

**EDA (6):** null\_percentages.png, pickup\_day\_distribution\_2024.png, pickup\_hour\_distribution.png, top\_10\_pickup\_zones\_2024.png, total\_amount\_log\_histogram.png, trip\_distance\_log\_histogram.png

**Q3 (3):** q3\_top\_zones\_total\_revenue.png, q3\_top\_zones\_revenue\_per\_mile.png, q3\_top\_zones\_revenue\_per\_minute.png

**Q4 (2):** q4\_card\_share\_by\_hour.png, q4\_avg\_tip\_rate\_card\_by\_hour.png

**Q5 (4):** q5\_borough\_flow\_heatmap\_trips.png, q5\_top\_borough\_flows\_by\_trips.png, q5\_top\_airport\_routes\_by\_trips.png, q5\_top\_airport\_routes\_by\_avg\_amount.png

**Q6 (5):** q6\_top\_positive\_net\_pickups.png, q6\_top\_negative\_net\_pickups.png, q6\_top\_abs\_imbalance\_ratio.png, q6\_hourly\_heatmap.png, q6\_hourly\_mean\_imbalance.png

**Q6 OD-Halves (1):** q6\_od\_halves\_scaling.png

## F. Πίνακας Κάλυψης

Ο πλήρης πίνακας κάλυψης δίνεται στο αρχείο ΠΙΝΑΚΑΣ\_ΚΑΛΥΨΗΣ.xlsx. Παρακάτω δίνεται συνοπτικός πίνακας για τα Q2 implementations:

| Q  | Διεπαφή     | CSV | Par. | Metrics / Plan                                                                                                    | App IDs             |
|----|-------------|-----|------|-------------------------------------------------------------------------------------------------------------------|---------------------|
| Q2 | DF built-in | ναι | ναι  | q2_df_builtin_csv_metrics.json, q2_df_builtin_metrics(CSV), q2_df_builtin_csv_plan.txt, q2_df_builtin_plan.(Par.) | spark-df-b3b3cd1... |
| Q2 | DF UDF      | όχι | ναι  | q2_df_udf_metrics.json, q2_df_udf_plan.txt                                                                        | spark-b552a366...   |
| Q2 | Spark SQL   | όχι | ναι  | q2_sql_metrics.json, q2_sql_plan.txt                                                                              | spark-f68dcb13...   |

**Table 43:** Συνοπτικός πίνακας κάλυψης Q2 – πλήρης στο ΠΙΝΑΚΑΣ\_ΚΑΛΥΨΗΣ.xlsx